SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Evidenčné číslo: FEI-16605-126888

Autonómne riadenie malého vozidla s detekciou prekážky

Bakalárska práca

2026 **Rudolf Tisoň**

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Evidenčné číslo: FEI-16605-126888

Autonómne riadenie malého vozidla s detekciou prekážky

Bakalárska práca

Študijný program:	aplikovaná informatika
Študijný odbor:	informatika
Školiace pracovisko:	Ústav informatiky a matematiky
Školiteľ:	Ing. Štefan Bucz, PhD.

2026 **Rudolf Tisoň**

Slovenská technická univerzita v Bratislave
Ústav informatiky a matematiky

Fakulta elektrotechniky a informatiky
2025/2026

ZADANIE BAKALÁRSKEJ PRÁCE

Autor práce:	Rudolf Tisoň
Študijný program:	aplikovaná informatika
Študijný odbor:	informatika
Evidenčné číslo:	FEI-16605-126888
ID študenta:	126888
Vedúci práce:	Ing. Štefan Bucz, PhD.
Vedúci pracoviska:	doc. Ing. Milan Vojvoda, PhD.
Názov práce:	**Autonómne riadenie malého vozidla s detekciou prekážky**
Jazyk, v ktorom sa práca vypracuje:	slovenský jazyk
Špecifikácia zadania:	Cieľom bakalárskej práce je návrh a implementácia algoritmu autonómneho riadenia malého vozidla s detekciou prekážky pred vozidlom. Implementácia navrhnutého algoritmu je realizovaná na platforme Arduino s využitím funkcií OpenCV.
Termín odovzdania práce:	06. 06. 2026

Poďakovanie

Na tomto mieste by som rád poďakoval svojmu vedúcemu práce Ing. Štefanovi Buczovi, PhD. za cenné rady a čas, ktorý mi venoval. Jeho odborná pomoc a podpora mali významný vplyv na výsledok mojej bakalárskej práce a boli značnou oporou pri jej písaní.

Abstrakt

Cieľom bakalárskej práce je návrh a implementácia algoritmu autonómneho riadenia malého vozidla s detekciou prekážky pred vozidlom. Implementácia navrhnutého algoritmu je realizovaná na platforme Arduino s využitím funkcií OpenCV.

Kľúčové slová

Arduino, OpenCV, Python, detekcia prekážky, autonómne vozidlo

Abstract

The aim of the bachelor's thesis is to design and implement an algorithm for autonomous control of a small vehicle with obstacle detection in front of the vehicle. The implementation of the proposed algorithm is carried out on the Arduino platform using OpenCV functions.

Keywords

Arduino, OpenCV, Python, obstacle detection, autonomous vehicle

Obsah

Úvod **12**

1 Autonómne vozidlá **13**
1.1 Čo je to autonómne vozidlo? . . . 13
1.2 Úrovne autonómnych vozidiel . . . 13
1.2.1 Úroveň 0 . . . 14
1.2.2 Úroveň 1 . . . 14
1.2.3 Úroveň 2 . . . 14
1.2.4 Úroveň 3 . . . 14
1.2.5 Úroveň 4 . . . 14
1.2.6 Úroveň 5 . . . 14

2 Analýza súčasného stavu **15**
2.1 Aktuálny stav technológie . . . 15
2.1.1 Umelá inteligencia . . . 15
2.1.2 Senzory . . . 16
2.2 Použitie autonómnych vozidiel . . . 16
2.2.1 Autonómne taxi služby . . . 16
2.2.2 Autonomizácia donášky jedla . . . 17

3 Komponenty systému **18**
3.1 Arduino Nano ESP32 mikrokontrolér . . . 18
3.2 ESP32-CAM + OV2640 kamera . . . 18
3.3 HC-SR04 Ultrazvukový senzor . . . 19
3.4 DRV8833 driver pre motorčeky . . . 19
3.5 Ďalšie elektrické komponenty . . . 20
3.6 Server . . . 20

4 Softvér **21**
4.1 C++ . . . 21
4.2 Python . . . 21
4.3 OpenCV . . . 21
4.4 Ultralytics YOLOv8 . . . 22

5 Návrh a implementácia **23**
5.1 Návrh komunikácie komponentov . . . 23
5.2 Návrh rámu a rozloženie komponentov . . . 24

5.3 Montovanie vozidla 24

6 Detekcia vozovky **25**

6.1 Region of interest 25

6.2 Hľadanie svetlých regiónov 25

6.3 Hľadanie kontúr vozovky 25

6.4 Interpretácia dát 25

7 Detekcia prekážky **26**

7.1 Ultrazvukový senzor 26

7.2 CNN 26

7.3 Interpretácia dát 26

8 Metodika a testovanie **27**

8.1 Metodika 27

8.2 Testovanie 27

9 Výsledky **28**

Záver **29**

Literatúra **30**

Použitie nástrojov umelej inteligencie 32

A Algoritmus **33**

B Výpis dlhého kódu **34**

C Slovníček pojmov **35**

Zoznam obrázkov a tabuliek

Zoznam značiek a skratiek

ADR	Autonómne doručovacie roboty
AI	Umelá inteligencia
API	Application programming interface
AV	Autonómne vozidlo
CNN	Convolutional Neural Network
CPU	Central Processing Unit
DC	Direct Current
GPIO	General-purpose input/output
GPS	Globálny polohovací systém
GPU	Graphics Processing Unit
IDE	Integrated Development Enviroment
LiDAR	Light Detection and Ranging
RADAR	Radio Detection and Ranging
RAM	Random Access Memory
RPM	Revolutions per minute
YOLO	You Only Look Once

Zoznam algoritmov

Zoznam výpisov kódov

Úvod

TODO

1 Autonómne vozidlá

1.1 Čo je to autonómne vozidlo?

Autonómne vozidlo (AV), niekedy nazývané aj samoriadiace auto je dopravný prostriedok, ktorý, na rozdiel od tradičných vozidiel nevyžaduje vodiča. Autonómne vozidlá vykonávajú túto úlohu pomocou viacerých hardvérových a softvérových systémov. Hoci ani v roku 2026 nemá termín 'samoriadiace' jednotnú štadardnú definíciu, hlavným cieľom týchto technológií zostáva eliminácia ľudských chýb, zvýšenie efektivity premávky a sprístupnenie prepravy ľudom, ktorí nie sú schopní šoférovať sami.

Na vnímanie okolia vozidla používame senzory detekcie objektov. Systém vnímania používa kamery, Radio Detection and Ranging (RADAR), Light Detection and Ranging (LiDAR) a ultrazvukové senzory, pričom každý z nich má špecifickú funkciu. Autonómne vozidlá často pracujú s čiastočne neznámym a dynamickým prostredím, preto si musia vystavať model svojho prostredia a zároveň sa v ňom lokalizovať. Tento proces je známy pod skratkou SLAM (súčasná lokalizácia a mapovanie). Spočíva v spracovaní dát zo senzorov, máp a systéme globálneho polohovacieho systému GPS, vďaka čomu si zariadenie vytvorí model prostredia a určí v ňom svoju polohu v reálnom čase [1].

Tretí systém je zodpovedný za plánovanie a rozhodovanie. Na základe dát z predchádzajúcej vrstvy vozidlo vyhodnocuje a reaguje na vývoj dopravnej situácii. Táto vrstva má mnoho funkcií od plánovania trasy po vyhýbanie sa prekážkam. Najčastejšie sa používajú modely strojového učenia, vrátane neurónových sietí.

Posledným kľúčovým článkom je konanie a ovládanie. Systém ovládania vozidla premení abstraktné požiadavky predchádzajúcej vrstvy na fyzické pohyby auta. Zodpovedá za smerové riadenie, zrýchľovanie a brzdenie. Pokročilé algoritmy zároveň zabezpečujú, aby pohyb bol plynulý, stabilný a rešpektoval limitácie podvozku. Vďaka integrácii týchto systémov dokáže autonómne vozidlo navigovať v komplexných dopravných situáciách s minimálnou až nulovou potrebou ľudského zásahu.

1.2 Úrovne autonómnych vozidiel

Úrovne autonómnych vozidiel sú definované organizáciou SAE International v štandarde SAEJ3016. Tento dokument delí automatizáciu riadenia do šietstich stupňov (0-5) podľa toho, akú časť jazdy zabezpečuje systém a akú úlohu ešte stále zohráva vodič. O samoriadiacich autách sa často hovorí ako o jednej kategórii, no v praxi ide o postupný vývoj od minimálnej podpory riadenia až po úplnú autonómiu vozidla bez zásahu človeka [2].

1.2.1 Úroveň 0

Žiadna automatizácia Na tejto úrovni všetky činnosti vykonáva ľudský vodič. Vozidlo môže mať bezpečnostné systémy, ako napríklad upozornenie opustenia jazdného pruhu, no samotné riadenie je plne v rukách človeka.

1.2.2 Úroveň 1

Asistované riadenie Systém pomáha s postranným alebo pozdĺžnym riadením vozidla ale nie v obidvoch prípadoch naraz. Sem patria asistencie ako udržiavanie rýchlosti (tempomat) alebo mierne korigovanie smeru. Vodič však musí neustále sledovať situáciu na vozovke a mať ruky na volante.

1.2.3 Úroveň 2

Čiastočná automatizácia Vozidlo dokáže súčasne riadiť smer aj rýchlosť, stále však platí, že vodič nepretržite dohliada na jazdu a je pripravený zasiahnuť v prípade núdze. Systém vykonáva viac úloh riadenia naraz, no zodpovednosť upadá na človeka.

1.2.4 Úroveň 3

Podmienená automatizácia Jazda v špecifickej situácii je automatizovaná a vodič nemusí aktívne sledovať okolie. Ak však systém vyhodnotí, že situáciu nezvládne, kontrola vozidla sa vráti vodičovi. Vodič musí byť pripravený prevziať kontrolu nad vozidlom.

1.2.5 Úroveň 4

Vysoká automatizácia Na tejto úrovni je vozidlo schopné zvládnuť jazdu úplne samo v rámci definovaných prostredí alebo podmienok. V prípade, že sa vozidlo dostane mimo týchto podmienok, dokáže bezpečne zastaviť. Prítomnosť ľudského šoféra nie je nutná.

1.2.6 Úroveň 5

Plná automatizácia Najvyšší stupeň automatizácie, vozidlo dokáže jazdiť samostatne za všetkých podmienok, v ktorých dokáže jazdiť človek. Neexistuje potreba vodiča. Vozidlo zastaví v prípade zlyhania určitých modulov riadenia.

2 Analýza súčasného stavu

2.1 Aktuálny stav technológie

V posledných rokoch sme zaznamenali nárast vydaní automobilov tretej úrovne autonómnosti, autonómne taxi služby sa stávajú realizovateľným spôsobom dopravy v mestách a dostali sme prvé ukážky kamiónov bez nutnosti ľudského vodiča [3][4].

Vďaka vývoju v oblasti umelej inteligecie a zvýšenia výkonu výpočtových platforiem sme zaregistrovali značný pokrok v technológiách autonómnych vozidiel. Výrobcovia sa snažia zlepšovať kombinácie RADARových, LiDARových a kamerových dát tak, aby boli robustnejšie voči dopravným a poveternostným podmienkam. Pokračuje snaha v návrhu scenárov pre hraničné sitúacie, čím sa zlepší percepčná schopnosť autonómnych systémov a zrýchli ich nasadenie [5][6].

Autonómne vozidla zaznamenali značnú investíciu ale aj kontrolu zo strany štátnych a nadnárodných organizácií. Spoločnosti, ktoré poskytujú služby samoriadiacich vozidiel rozširujú svoju dostupnosť, znižujú počet senzorov a náklady na hardvér. Hoci technológický pokrok napreduje, integrácia do infraštruktúry mesta zostáva podstatnou výzvou pre adopciu AV do dopravy. Štandard SAE International preto opisuje plán prechodu od asistencie šoférovania po plne autonómnu prevádzku [7][8].

2.1.1 Umelá inteligencia

Umelá inteligencia (AI) vykonáva dôležitú funkciu v percepčnom, rozhodovacom a plánovacom systéme autonómneho vozidla, čím nahrádza rolu ľudského vodiča. Moderné systémy používajú strojové učenie (machine learning) na detekciu hazardov na ceste, klasifikáciu dopravných značiek a sledovanie a predikciu pohybu chodcov a ostatných vozidiel [9].

V súčasnosti sa autonómne modely trénujú na obrovskom množstve anotovaných obrázkov, videí, simulácií a skutočných jazdných dát, aby v praxy zvládli širokú škálu scenárov. Hlboké učenie (deep learning) a učenie posilňovaním (reinforcement learning) sa používajú v novodobých autonómnych vozidlách. Deep learning, podskupina strojového učenia, pracuje na princípe viacvrstvových neurónových sietí, čím sa fungovaním podobá ľudskému mozgu. Reinforcement learning mení správanie modelu využitím systému odmien a penalizácií [10].

Napriek značnej komplexnosti zostáva riešenie hraničných prípadov (edge cases) zásadnou výzvou pre dnešné systémy. Potreba veľkého množstva tréningových dát a vysoká hranica bezpečnosti a spoľahlivosti výrazne spomaľuje nasadenie vozidiel do reálnej premávky.

2.1.2 Senzory

Senzory sú spôsob akým autonómne vozidlá vnímajú svoje okolie. V súčasnosti sa v autách využíva kombinácia kamier, LiDARových, RADARových a ultrazvukových senzorov [11].

Kamery predstavujú najrozšírenejší typ senzorov; sú nákladovo efektívne, no citlivé na zlé osvetlenie a počasie. Používajú sa na detekciu jazdných pruhov, rozpoznávanie dopravných značiek a identifikáciu chodcov a vozidiel. RADAR využíva elektromagnetické vlny na meranie vzdialenosti a rýchlosti. Používa sa najmä pre detekciu vzdialených objektov aj v nepriaznivých poveternostných podmienkach (dážď, hmla, sneh). LiDAR používa laserové impulzy na vytvorenie detailného trojrozmerného modelu okolia, no okrem vysokých nákladov je aj viac náchylný na zlé počasie. Ultrazvukové senzory majú využitie v detekcii objektov na krátke vzdialenosti, napríklad pri parkovacích manévroch.

Súčasný vývoj v oblasti senzorov sa zameriava primárne na zvyšovanie presnosti meranie, optimalizovanie počtu potrebných senzorov a výrazné znižovanie ich ceny. Výrobcovia taktiež zefektivňujú kombinovanie dát viacerých senzorov, tzv. senzorovú fúziu, čím zvyšujú presnosť a spoľahlivosť systému.

2.2 Použitie autonómnych vozidiel

Autonómne vozidlá ponúkajú široké spektrum využitia, pričom ich možnosti sa v posledných rokoch rozširujú. K najpozoruhodnejším oblasťiam ich využitia patrí doprava. Hlavným cieľom je zvýšiť bezpečnosť a plynulosť premávky. Ďalšie využitie je v logistike tovaru, kde nahrádzajú rutinnú manuálnu prácu tradične vykonávanú ľudmi.

2.2.1 Autonómne taxi služby

Autonómne taxi služby, často nazývané robo-taxíky predstavujú jednu z najpokročilejších foriem využitia autonómnych služieb. Proces od objednania, naplánovania trasy po prepravy pasažierov je plne automatizovaný. Mnohí výrobcovia automobilov, technologické spoločnosti a štátne organizácie investujú zdroje do vývoju robo-taxíkov. Na popredí je firma Waymo, ktorá je dcérskou spoločnosťou Alphabet. Ich automobily, ktoré spĺňajú štvrtú úroveň autonómie, využívajú LiDAR, RADAR a kamery na vytvorenie trojrozmerného obrazu prostredia. S každou ďalšou generáciou vozidiel redukujú počet senzorov, čím znižujú náklady na výrobu a zlepšujú škálovateľnosť projektu.

Alternatívny prístup zvolila spoločnosť Tesla, so službou Robotaxi a systémom FSD (Full Self-Driving), forma autónomneho riadenia tretieho stupňa. Používa kamerový systém s interpretáciou dát pomocou umelej inteligencie namiesto finančne nákladových

LiDAR senzorov. Ľudský operátor dohliada nad jazdou a je pripravený prevziať kontrolu nad riadením, no v roku 2026 začala firma zavádzať vozidlá bez dozoru do ich flotily [12].

Ďalším dôležitým hráčom je spoločnosť Nvidia, s modelom Alpamayo 1. Tento open source model uvažovania je trénovaný na riešenie komplexných a kritických dopravných situácií. Toto voľné riešenie má za úlohu urýchliť adopciu štvrtej a piatej úrovne AV do bežnej premávky.

2.2.2 Autonomizácia donášky jedla

Autonómne doručovacie roboty (ADR) sa používajú v súčasnosti v univerzitných kampusoch a mestách na donášku jedla. Poskytujú takzvanú last-mile delivery (dodanie na poslednú míľu) a fungujú na štvrtej úrovni autonómie. Primárne využívané na chodníkoch alebo cyklochodníkoch, doručovacie roboty sú schopné prekonávať križovatky, vyhýbať sa prekážkam a doručovať tovar na vzdialenosť pár kilometrov [13].

ADR používajú zväčša kombináciu kamier a počítačového videnia na navigovanie, týmto spôsobom zabezpečujú nížšie náklady na výrobu, s väčšou mierou škalovateľnosti. Niektorí výrobcovia sa vyhýbajú používaniu GPS, pretože neposkytuje dostatočnú mieru presnosti [14].

Autonómna donáška jedla zaznamenala výrazný rozvoj počas pandémie COVID-19. Mnohé spoločnosti poskytujúce donášku jedla, ako napríklad Uber Eats a DoorDash, ale aj logistické spoločnosti ako Amazon, Walmart a Google začali investovať do vývoja ADR. Jedným z priekopníkov v tejto oblasti je spoločnosť Starship Technologies, ktorá výrazne rozšírila svoju flotilu práve počas pandémie. Zatiaľ čo donáška pomocou pozemných robotov je bežná, mnohé spoločnosti investujú aj do vývoja doručovania pomocou autonómnych dronov.

3 Komponenty systému

V tejto kapitole si preberieme použité komponenty celkového systému. Výber správnych súčastí v rámci limitácií bakalárskej práce je kľúčový pre získanie lepších výsledkov. V tejto práci sme boli obmedzený na platformu mikrokontrolérov Arduino a použitím knižnice počítačového videnia OpenCV.

3.1 Arduino Nano ESP32 mikrokontrolér

Mikrokontrolér je malý počítač na jednom integrovanom obvode. Arduino je taliánska open source hardvérová a softvérová firma, ktorá dizajnuje a vyrába mikrokontroléry na výrobu rôznych zariadení.

Arduino Nano je rodina kompaktných a nákladovo efektívnych mikrokontrolérov. Nano ESP32 je osadený čipom ESP32-S3, ktorý integruje možnosti Wi-Fi a Bluetooth. Mikrokontrolér poskytuje správnu rovnováhu veľkosti a výkonu, s dostatočným počtom pinov na pripojenie periférií.

V našej práci používame Arduino Nano ESP32 ako riadiacu jednotku, ktorá získava vstupy od ostatných komponentov a podľa nich riadi mechanické časti vozidla [15].

Technické parametre:

- Rozmery: 18 * 45mm
- Vstupné/výstupné napätie: 3.3V
- Počet GPIO pinov: 48
- Komunikačné rozhrania: UART, I2C, SPI
- Rýchlosť procesora: 240Mhz
- Veľkosť ROM: 384kB
- Veľkosť SRAM: 512kB
- Veľkosť RAM: 8MB

3.2 ESP32-CAM + OV2640 kamera

Vývojová doska ESP32-CAM integruje Wi-Fi a Bluetooth modul spolu s rozhraním na pripojenie 2MPx kamerový senzor OV2640. Táto kombinácia nám poskytuje oddelenú implementáciu prenosu videa, čím uvolníme výpočtovú záťaž hlavného čipu. Senzor

OV2640 disponuje s natívnym rozlíšením 1600 x 1200 pixelov a obrazovou frekvenciou 60 FPS, čo poskytuje dostatočnú výkonovú rezervu [16][17].

Technické parametre:

- Rozmery: 27 * 40mm
- Pracovné napätie: 2.2V - 3.6V
- Rozlíšenie kamery: 1600 x 1200
- Frame rate kamery: 60FPS (pri CIF formáte)
- Rýchlosť procesora: 240Mhz
- Veľkosť FLASH: 4MB
- Veľkosť PSRAM: 4MB

3.3 HC-SR04 Ultrazvukový senzor

Ultrazvukový senzor je zariadenie, ktoré generuje a deteguje ultrazvukové vlny. Tieto vlny sa odrazia od objektu a vrátia sa k prijímaču. Meraním času, za ktorý sa vlna vráti a znalosť rýchlosti zvuku dokážeme určiť vzdialenosť objektu.

HC-SR04 je nákladovo efektívne riešenie na detekciu prekážky pred vozidlom. Používame ho ako sekundárny systém na núdzové zastavenie vozidla v prípade, že kamerový systém nedetekuje prekážku [18].

Technické parametre:

- Rozmery: 20 * 45 * 15mm
- Pracovné napätie: 5V
- Maximálna vzdialenosť: 4n
- Minimálna vzdialenosť: 2cm
- Merací úhol: 15°

3.4 DRV8833 driver pre motorčeky

Motor driver je zariadenie určené na riadenie motorov. Slúži na zosilnenie slabého signálu z riadiacej jednotky (napr. mikrokontroléra), aby motoru poskytol potrebné napätie a prúd. Mnohé moduly poskytujú možnosť ovládať rýchlosť aj smer otáčania motorov.

DRV8833 sme použili na nezávislé riadenie dvoch DC motorov. Integrovaný obvod obsahuje dvojitý H-mostík, ktorý umožnuje meniť polaritu napätia, a tým aj smer otáčania motorov. Modul má štyri vstupné piny (dva pre každý motor), pomocou ktorých možno ovládať rýchlosť a smer otáčania [19].

Technické parametre:

- Rozmery: 5 * 4 mm
- Logické napätie: 2.7V - 10.8V
- Drive napätie: 3V - 10V
- Drive prúd: 1.5A (MAX pre jeden mostík)
- Maximálny výkon: 15W

3.5 Ďalšie elektrické komponenty

V implementácií sme použili Li-Ion akumulátor s napätím 7.4V a kapacitou 1500mAh. Pohon zabezpečujú dva DC motorčeky s prevodovkou na 200RPM pri 3V. Kvôli ochrane komponentov vyžadujúce 5V napájanie sme do systému zapojili menič napätia (step-down buck converter). Súčasťou zapojenia je taktiež kolískový prepínač na vypnutie/zapnutie systému.

3.6 Server

Server je počítač alebo softvér, ktorý poskytuje dáta, zdroje alebo služby iným počítačom. Táto architektúra sa nazýva klient-server model, kde server je podradený klientovi.

Vzhľadom na obmedzený výpočtový výkon mikrokontrolérov Arduino, ktoré nie sú schopné vykonávať komplexné výpočty neurónových sietí v reálnom čase, sme do systému zaradili centrálny server. Ten zabezpečuje spracovanie obrazu a koordináciu bezdrótových periférií. V našej implementácii túto úlohu plní laptop, ktorý zároveň slúži ako prístupový bod pre Wi-Fi sieť.

4 Softvér

V nasledovnej časti sa oboznámime s použitým softvérom, ktorý nám umožnuje preklad požiadaviek systému na skutočné inštrukcie vykonateľné hardvérom.

4.1 C++

C++ je programovací jazyk vyššej úrovne na všeobecné použitie, ktorý umožnuje pracovať s prostriedkami nízkej úrovne. Bjarne Stroustrup vyvinul C++ v roku 1983 ako rozšírenie jazyka C [20].

Mikrokontroléry Arduino je možné programovať pomocou jazykov C/C++ vďaka štandardnému rozhraniu pre programovanie aplikácií (API) známemu ako Arduino Programming Language. Toto API obsahuje funkcie a knižnice na ovládanie hardvéru mikrokontroléra. Projekt Arduino taktiež poskytuje vývojové prostredie Arduino IDE, v ktorom je kompilácia, integrácia knižníc a nahrávanie kódu zjednodušené.

V našej implementácii používame C++ pre programovanie nízkoúrovňového mikrokontroléru Arduino Nano ESP32 a kamerového modulu ESP32-CAM.

4.2 Python

Python je interpretovaný, interaktívny programovací jazyk vysokej úrovne, ktorý vytvoril Guido van Rossum. Je dynamicky typovaný, čo znamená, že typ premennej sa určuje za behu programu. Na rozdiel od jazykov C/C++, využíva Garbage Collection, vďaka čomu programátor nemusí manuálne riešiť alokovanie a uvolňovanie pamäte. Štruktúra kódu je definovaná odsadením, čím sa výrazne zvyšuje čitateľnosť kódu [21].

V súčasnosti je Python populárnou voľbou v oblasti umelej inteligencie, vďaka jeho jednoduchosti a rozširenej podpore knižníc pre prácu s neurónovými sieťami. Hoci je Python ako jazyk pomalší, pri vývoji AI to nepredstavuje prekážku, keďže kritické výpočty sú vykonávané nízkoúrovňovým kódom optimalizovaným pre CPU a GPU.

V našej implementácii používame Python na vytvorenie Wi-Fi servera, spracovanie dát z kamery a následnú interpretáciu výsledkov do podoby príkazov pre pohyb kolies.

4.3 OpenCV

OpenCV je knižnica programovacích funkcií určených na počítačové videnie v reálnom čase, ktorú pôvodne vyvinula spoločnosť Intel. Využíva sa v oblastiach detekcie objektov, tvárí a gest, pri vizuálnej odometrii, vnímaní hĺbky či v augmentovanej realite. Knižnica OpenCV je napísaná v programovacom jazyku C++, no ponúka rozhrania pre integráciu v ďalších jazykoch, ako sú Python, Java alebo MATLAB [22][23].

V našej implementácii používame OpenCV na detekciu vozovky a analýzu jazdných pruhov.

4.4 Ultralytics YOLOv8

YOLOv8 je model umelej inteligencie od spoločnosti Ultralytics určený na detekciu objektov v reálnom čase. Tento model je založený na konvolučných neurónových sietí (CNN), čo je typ dopredných neurónových sietí, ktoré využívajú matematickú konvolúciu na učenie vzorov zo vstupu. Model You Only Look Once (YOLO) vyžaduje iba jednu doprednú propagáciu (forward pass) na vytvorenie predpokladu. Pre programovací jazyk Python existuje jednoduché rozhranie, ktoré prácu s modelom zjednodušuje [24][25].

Tento model je už predtrénovaný na rozsiahlych datasetoch, vďaka čomu je pripravený na okamžitú implementáciu bez nutnosti zložitej konfigurácie. V našej implementácii ho využívame na detekciu prekážky v dráhe vozidla.

5 Návrh a implementácia

Vhodný návrh architektúry je kľúčový pre efektívnu spoluprácu všetkých komponentov. Počas vývoja bolo otestovaných niekoľko prístupov, kým sa nepodarilo dosiahnuť optimálne riešenie. V tejto kapitole popíšeme použitý dizajn a jeho následnú implementáciu.

5.1 Návrh komunikácie komponentov

Komunikácia komponentov predstavuje dôležitý aspekt projektu, pretože je nutné aby si jednotlivé časti mohli synchrónne vymieňať a spracovať dáta. Systém je navrhnutý tak, aby v prípade výpadku jedného alebo viacerých komponentov dokázal bezpečne zastaviť vozidlo.

Dôsledkom nízkeho výpočtového výkonu mikrokontrolérov Arduino sme použili v našej implementácii model klient-server. V danej štruktúre vystupujú dva typy entít; nadradení klienti iniciujú požiadavky na pasívny server, ktorý posiela odpovede klientom.

Server je v našom projekte laptop, ktorý taktiež spúšťa Wi-Fi sieť na komunikáciu s komponentmi. Všetky funkcie webserveru sme programovali pomocou jazyka Python. Bezdrôtový pripojný bod sme vytvorili NetworkManagerom, nástrojom na konfiguráciu sieťových zariadení v operačnom systéme Linux, pomocou ktorého sme sieťovú kartu našeho laptopu zmenili na prípojný bod Wi-Fi hotspotu. Na spustenie tohto programu v Pythone sme použili knižnicu subprocess.

ESP32-CAM pracuje ako klient, ktorý posiela obrázkové dáta na server za pomoci Wi-Fi. Po pripojení na server začne cez protokol HTTP na porte 81 vysielať video z kamery OV2640. Obrázky sú rozlíšenia QVGA (t.j 320x240 pixelov) s formátom JPEG. Nový obrázok sa pošle každých 30ms, čo znamená, že stream má približne 30FPS.

Vďaka statickej IP adrese dokážeme serveru povedať na akej URL má očakávať obrázky. Funkcia VideoCapture z knižnice OpenCV má podporu pre spracovanie obrazu z URL. Po interpretovaní dát, server pošle požiadavku na Arduino Nano. Odpoveď sa odošle cez UDP socket, ideálne pre aplikácie fungujúce v reálnom čase, IP adrese mikrokontroléra na porte 5005. Komunikáciu sprostredkuje Python knižnica socket. Poslané dáta sú vo forme 2 bytov, čo je najmenší potrebný buffer na uloženie údajov o riadení.

Arduino príjme UDP packet a súčasne získa nameránu vzdialenosť z ultrazvukového senzora. Snímač sa spúšťa v intervaloch 50ms, z dôvodu efektívneho využitia výpočtového výkonu. Ak vyhodnotí, že objekt pred senzorom je do 10 cm, vozidlo zastaví, inak nastaví riadenie motorov. Každému z motorčekov sú priradené dva výstupné piny – pulse width modulation (PWM) a smerový (DIR) pin. PWM riadi rýchlosť a DIR smer

otáčania kolies. Signály z pinov sú zaslané na DRV8833, ktorý fyzicky poháňa dva DC motory.

5.2 Návrh rámu a rozloženie komponentov

Správny návrh rámu a rozloženia komponentov na ňom je doležité pre správne fungovanie celého systému. V našej implementácii sme sa zamerali na minimalizovanie váhy vozidla a maximalizovanie kompaktnosti komponentov a tým ich zohranie.

Na návrh rámu sme použili softvér Blender, populárny všeobecne používaný program na dizajn, modelovanie a animáciu, ktorý je taktiež schopný exportovať vo formáte '.stl', ideálny pre 3D tlač. Po odmeraní všetkých komponetov, sme začali pracovať na prototypu rámu. Vyskúšali sme mnoho návrhov, kde sme otestovali rôzne rozloženia a orientácie komponentov. Vybrali sme si dvojkolesový dizajn vpredu so zadnou vidlicou, ktorá sa dá vymeniť (v prípade opotrebovania alebo zmeny povrchu). Najťažšie komponenty – batériu a menič napätia – sme umiestnili na spodok vozidla pre zníženie ťažiška a zvýšenie stability. Pridali sme držiak na kameru a ultrazvukový senzor na stabilizovanie obrazu. Kolesá sme navrhli ako duté valce na minimalizovanie váhy.

Model bol vytlačený na tlačiarni Bambulab A1 Mini, použitím filamentu kyseliny polymliečnej (PLA). Podobne sme pre kolesá vozidla využili odolnejšiu náplň polyetyléntereftálatu modifikovaného glykolom (PETG).

5.3 Montovanie vozidla

Po získaní všetkých potrebných komponentov sme začali s montovaním vozidla. Na prepojenie komponentov sme použili nepájivé pole a farebne odlíšené kábliky. Podľa definície pinov v kóde sme dokopy zapojili jednotlivé elektronické prvky. Na rám vozidla sme pripevnili nepájivé pole pomocou adhezívneho prvku na jeho spodku.

6 Detekcia vozovky

6.1 Region of interest

6.2 Hľadanie svetlých regiónov

6.3 Hľadanie kontúr vozovky

6.4 Interpretácia dát

7 Detekcia prekážky

7.1 Ultrazvukový senzor

7.2 CNN

7.3 Interpretácia dát

8 Metodika a testovanie

8.1 Metodika

8.2 Testovanie

9 Výsledky

Záver

TODO

Literatúra

1. *2020 Autonomous Vehicle Technology Report* [online]. Wevolver, 2020. [cit. 2026-03-02]. Dostupné z: https://www.wevolver.com/article/2020.autonomous.vehicle.technology.report.
2. *J3016_202104: Taxonomy and Definitions for Terms Related to Driving Automation Systems for On-Road Motor Vehicles: Levels or categories of driving automation*. Warrendale, PA, USA: SAE International, 2021.
3. PAREKH, D. et al. A Review on Autonomous Vehicles: Progress, Methods and Challenges. *Electronics* [online]. 2022 [cit. 2026-03-05]. ISSN 2079-9292. Dostupné z DOI: 10.3390/electronics11142162.
4. ANI KELKAR, K. H.; KELLNER, M. *Where to next? Insights from autonomous-vehicle experts* [online]. McKinsey & Company, 2026. [cit. 2026-03-04]. Dostupné z: https://www.mckinsey.com/features/mckinsey-center-for-future-mobility/our-insights/future-of-autonomous-vehicles-industry.
5. MARKUS, F. *The Great Sensor War Behind Self-Driving Cars Just Got Way More Interesting* [online]. Motortrend, 2026. [cit. 2026-03-04]. Dostupné z: https://www.motortrend.com/news/latest-auto-lidar-radar-technology-ces-2026.
6. SOARES, J. *NVIDIA Announces Alpamayo Family of Open-Source AI Models and Tools to Accelerate Safe, Reasoning-Based Autonomous Vehicle Development* [online]. Nvidia Newsroom, 2026. [cit. 2026-03-04]. Dostupné z: https://nvidiannews.nvidia.com/news/alpamayo-autonomous-vehicle-development.
7. KOLLEWE, J. *Nvidia and UK Wealth Fund invest in British autonomous driving startup Oxa* [online]. The Guardian, 2026. [cit. 2026-03-04]. Dostupné z: https://www.theguardian.com/technology/2026/mar/04/nvidia-uk-wealth-fund-invest-british-autonomous-driving-startup-oxa.
8. *Waymo Slims Sensors to Drive Down Robotaxi Costs* [online]. Autonomous Vehicles & AI, 2026. [cit. 2026-03-04]. Dostupné z: https://www.autonomous-vehicles-conference.com/news/waymo-slims-sensors-to-drive-down-robotaxi-costs.
9. HAMZA, G.; ES-SADEK, M.; TAHER, Y. Artificial Intelligence In Self-Driving: Study of Advanced Current Applications [online]. 2023 [cit. 2026-03-08]. Dostupné z DOI: 10.31224/3209.

10. GRIGORESCU, S.; TRASNEA, B.; COCIAS, T.; MACESANU, G. A survey of deep learning techniques for autonomous driving. *Journal of Field Robotics* [online]. 2019, **37**, 362–386 [cit. 2026-03-08]. Dostupné z DOI: 10.1002/rob.21918.

11. BADUE, C. et al. Self-driving cars: A survey. *Expert Systems with Applications* [online]. 2021, **165**, 113816 [cit. 2026-03-08]. ISSN 0957-4174. Dostupné z DOI: https://doi.org/10.1016/j.eswa.2020.113816.

12. SINGH, K. *Tesla Launches Unsupervised Robotaxi Rides in Austin* [online]. Not a Tesla App, 2026. [cit. 2026-03-05]. Dostupné z: https://www.notateslaapp.com/news/3527/tesla-launches-unsupervised-robotaxi-rides-in-austin.

13. SRINIVAS, S.; RAMACHANDIRAN, S.; RAJENDRAN, S. Autonomous robot-driven deliveries: A review of recent developments and future directions. *Transportation Research Part E: Logistics and Transportation Review* [online]. 2022, **165** [cit. 2026-03-07]. ISSN 1366-5545. Dostupné z DOI: https://doi.org/10.1016/j.tre.2022.102834.

14. KOETSIER, J. *Starship's 2,700 Robots Have Made 9M Deliveries. Now They're Coming To Your City* [online]. Forbes, 2025. [cit. 2026-03-07]. Dostupné z: https://www.forbes.com/sites/johnkoetsier/2025/10/15/starships-2700-robots-have-made-9m-deliveries-now-theyre-coming-to-your-city/.

15. *Arduino® Nano ESP32* [SKU: ABX00083]. Arduino®, [b.r.]. Dostupné tiež z: https://docs.arduino.cc/resources/datasheets/ABX00083-datasheet.pdf.

16. *ESP32-CAM Development Board* [SKU: DFR602]. DFRobot, [b.r.]. Dostupné tiež z: https://media.digikey.com/pdf/Data%20Sheets/DFRobot%20PDFs/DFR0602_Web.pdf.

17. *OV2640 Color CMOS UXGA (2.0 MegaPixel) CAMERA CHIPTM with OmniPixel2TM Technology*. OmniVision, [b.r.]. Dostupné tiež z: https://www.uctronics.com/download/cam_module/OV2640DS.pdf.

18. *Ultrasonic Ranging Module HC - SR04*. ElecFreaks, [b.r.]. Dostupné tiež z: https://cdn.sparkfun.com/datasheets/Sensors/Proximity/HCSR04.pdf.

19. *DRV8833 Dual H-Bridge Motor Driver* [SKU: SLVSAR1E]. Texas Instruments, [b.r.]. Dostupné tiež z: https://www.ti.com/lit/ds/symlink/drv8833.pdf?ts=1773296972820.

20. STROUSTRUP, B. *C++ Programming Language* [online]. 4. vyd. Addison-Wesley, 2013 [cit. 2026-03-16]. ISBN 978-0-321-56384-2. Dostupné z: https://chenweixiang.github.io/docs/The_C++_Programming_Language_4th_Edition_Bjarne_Stroustrup.pdf.

21. KUHLMAN, D. *A Python Book: Beginning Python, Advanced Python, and Python Exercises* [online]. Platypus Global Media, 2011 [cit. 2026-03-16]. ISBN 978-0984221233. Dostupné z: https://web.archive.org/web/20120623165941/http://cutter.rexx.com/~dkuhlman/python_book_01.html.

22. KARI PULLI Anatoly Baksheev, K. K.; ERUHIMOV, V. Realtime Computer Vision with OpenCV. *Queue* [online]. 2023, **10**(4) [cit. 2026-03-16]. ISSN 1542-7730. Dostupné z DOI: 10.1145/2181796.

23. *Open Source Computer Vision Library* [online]. OpenCV, 2025. [cit. 2026-03-16]. Dostupné z: https://github.com/opencv/opencv.

24. TERVEN, J.; CÓRDOVA-ESPARZA, D.-M.; ROMERO-GONZÁLEZ, J.-A. A Comprehensive Review of YOLO Architectures in Computer Vision: From YOLOv1 to YOLOv8 and YOLO-NAS. *Machine Learning and Knowledge Extraction* [online]. 2023, **5**(4), 1680–1716 [cit. 2026-03-16]. ISSN 2504-4990. Dostupné z DOI: 10.3390/make5040083.

25. JOCHER, G.; QIU, J.; CHAURASIA, A. *Ultralytics YOLO* [online]. 2023. [cit. 2026-03-16]. Dostupné z: https://github.com/ultralytics/ultralytics.

Použitie nástrojov umelej inteligencie

penis

Dodatok A: Algoritmus

TODO

Dodatok B: Výpis dlhého kódu

TODO

Dodatok C: Slovníček pojmov

TODO